

CLI: main_loading

Dokumente laden und als LangChain-Dokument melden

Zweck

main_loading.py ist die Bedienungsschicht über der Bibliothek rag_project.pipeline.loading. Getrennt gehalten, damit die Bibliothek keine Kommandozeile kennt: Dort liegt das Laden, hier liegen Argumente, Ausgabe, Exit-Codes und Dateischreiben.

Die CLI fährt nur die erste Stufe der Vorverarbeitung. Bereinigen und Chunken sind eigene Einstiege; der Gesamtlauf liegt in app/rag_app.py.

Aufruf

- `uv run loading` — lädt das Standarddokument aus der .env
- `uv run loading docs/handbuch.pdf` — lädt eine bestimmte Datei
- `uv run loading --show-paths --preview 400` — Pfade zeigen, dann laden
- `uv run loading --write docs/extrakt.txt` — Inhalte als Textdatei ablegen
- `uv run python -m rag_project.app.main_loading --help` — Übersicht der Optionen

Pfadauflösung

Ohne Argument liest die Anwendung die Pfade aus der .env: DOCS_DIR, DEFAULT_DOCUMENT und DOCUMENT_FILES. Ist DOCUMENT_FILES gefüllt, bestimmt diese kommasetrennte Liste die Auswahl und DEFAULT_DOCUMENT wird ignoriert. Findet sich nichts, greift der Fallback docs/handbuch.txt relativ zur Projektwurzel. Die Auflösung liegt gebündelt in rag_project.core.paths — alle drei CLIs nutzen dieselbe Funktion, damit es nicht drei leicht abweichende Varianten gibt.

Ebene	Quelle
1	Pfade auf der Kommandozeile
2	DOCUMENT_FILES aus der .env
3	DOCS_DIR und DEFAULT_DOCUMENT aus der .env
4	Fallback: docs/handbuch.txt zur Projektwurzel

Ein relativer Pfad wird zuerst gegen das Arbeitsverzeichnis geprüft und erst danach gegen DOCS_DIR. So gewinnt eine Datei im aktuellen Ordner, wenn beide existieren — ein Verhalten, das tests/test_paths.py ausdrücklich festhält.

Unterstützte Formate

Die Endung entscheidet, welcher Loader greift. Netzpunkte werden dagegen explizit angegeben, weil sie keine Endung tragen.

Quelle	Erkennung	Loader
.txt, .rst	Endung	TextLoader
.md, .markdown	Endung	UnstructuredMarkdownLoader
.csv	Endung	CSVLoader
.pdf	Endung	PyPDFLoader
http://, https://	explizit	WebBaseLoader für HTML, PyPDFLoader für PDF
wikipedia:	Präfix	WikipediaLoader
csv:	Präfix	CSVLoader für entfernte Dateien

Netzbasierte Quellen

Ein Argument mit dem Präfix src: ist eine Quelle, alles andere ist ein Pfad. Das Präfix ist nötig, damit die Anwendung beides trennt und der Pfadauflöser nur bekommt, was er prüfen kann — eine URL darf nicht gegen das Dokumentenverzeichnis geprüft werden.

- src:https://example.com/handbuch — Webseite als Text
- src:wikipedia:RAG — Wikipedia-Artikel
- src:csv:https://example.com/d.csv — entfernte CSV-Datei
- Gleichwertig als Option: --url, --wikipedia, --csv-url

Ohne --allow-remote listet die Anwendung die Quellen auf und fragt nach. Ein Lauf, der ungefragt das Netz anfasst, ist bei RAG unerwartet: Die Quelle ist nicht reproduzierbar, und der Aufruf kann lange dauern. Die Rückfrage ist die Voreinstellung.

Nicht reproduzierbar

- Derselbe Aufruf kann zu zwei Zeitpunkten verschiedene Inhalte liefern. Mit --write-jsonl wird der geladene Satz abgelegt und ein späterer Lauf kann ihn wiederverwenden.

Optionen

Option	Wirkung	Standard
paths	Quelldateien oder src:-Quellen als Positionsargumente	aus der .env
--preview N	Zeichen der Vorschau pro Datei, 0 schaltet sie ab	200
--encoding NAME	Kodierung für Text- und CSV-Dateien	utf-8
--show-paths	aufgelöste Pfade vor dem Laden anzeigen	aus
--progress	Fortschritt je Quelle nach stderr	aus
--quiet	nur die Zusammenfassung	aus
--url ADRESSE	Webseite laden, mehrfach angebbbar	—
--wikipedia THEMA	Wikipedia-Artikel laden, mehrfach angebbbar	—
--csv-url ADRESSE	entfernte CSV laden, mehrfach angebbbar	—
--wiki-lang CODE	Sprachversion für Wikipedia	de
--wiki-max-docs N	Zahl der Artikel je Thema	1
--allow-remote	Netzquellen ohne Rückfrage laden	aus
--write-jsonl DATEI	geladene Dokumente als JSONL ablegen	—
--write DATEI	Inhalte als Textdatei ablegen	—

Ausgabe

Der Ladebericht kommt aus `format_load_report(describe(documents))` und nennt je Dokument Pfad, Format und Größe. Fortschrittszeilen gehen nach `stderr`, damit `stdout` sauber bleibt und sich weiterleiten lässt. Die Vorschau zeigt die ersten Zeichen des ersten Dokuments, danach folgen dessen Metadaten.

Die Metadaten setzt der Loader selbst: `source`, `file_name`, `format`, `size_bytes` und `page_index`. Für entfernte PDFs kommt die Quelladresse hinzu.

Exit-Codes

Code	Bedeutung
------	-----------

Code	Bedeutung
0	Lauf erfolgreich
1	Fehler: Pfad nicht gefunden oder Format nicht unterstützt
2	Fehlende Abhängigkeit — ein Loader-Paket ist nicht installiert

Ein fehlendes Paket ist eine andere Ursache als eine unbekannte Endung und bekommt deshalb eine eigene Meldung und einen eigenen Code. Die Anwendung meldet es als fehlende Abhängigkeit, statt einen Importfehler durchzureichen.

PDF von einer Adresse

Wird eine PDF über eine Adresse geladen, legt die Anwendung die Datei nach dem erfolgreichen Parsen im Projektordner docs/ ab. Existiert dort bereits eine gleichnamige Datei, bleibt sie unverändert und die neue Fassung bekommt einen nummerierten Namen wie scan_1.pdf. Eine Adresse, die keine gültige PDF liefert, wird abgelehnt.

- `uv run loading --url "https://example.com/scan.pdf" --allow-remote`
- `uv run cleaning --url "https://example.com/scan.pdf" --allow-remote`
- `uv run chunking --url "https://example.com/scan.pdf" --allow-remote`

Wikipedia

Der Wikipedia-Loader liest den User-Agent aus der Umgebungsvariable WIKIPEDIA_USER_AGENT; Sprache, Höchstzahl und Suchbegriff werden durchgereicht. Fehlt das Paket wikipedia, greift dieselbe Meldung wie bei allen anderen fehlenden Abhängigkeiten.

- `uv run loading --wikipedia "Künstliche Intelligenz" --wiki-lang de --wiki-max-docs 2 --allow-remote`
- `uv run loading --wikipedia "Artificial intelligence" --wiki-lang en --wiki-max-docs 2 --allow-remote --write docs/artificial_intelligence.txt`

Testbezug

tests/test_main_loading.py ersetzt den Loader durch eine Attrappe und prüft, dass --write die Inhalte zweier Dokumente getrennt durch eine Leerzeile in die Zielfeile schreibt.

tests/test_remote_pdf_loader.py deckt den PDF-Pfad ab: Download, Metadaten, Speicherung unter docs/ und der Fall, dass eine vorhandene Datei nicht überschrieben wird.