

CLI: main_cleaning

Textbereinigung — Steuerzeichen, Leerraum, Silbentrennung

Zweck

main_cleaning.py ist die Bedienungsschicht über der Bibliothek rag_project.pipeline.cleaning. Die Bibliothek kennt keine Kommandozeile; hier liegen Argumente, Ausgabe, Dateischreiben und Exit-Codes.

Die Bereinigung ist die zweite Stufe der Vorverarbeitung und läuft zwischen Laden und Chunks. Ohne sie wandern Steuerzeichen, doppelte Leerzeichen und zerbrochene Silbentrennung in die Chunks und damit in die Embeddings.

Aufruf

- `uv run cleaning` — bereinigt das Standarddokument aus der `.env`
- `uv run cleaning docs/handbuch.txt` — bereinigt eine bestimmte Datei
- `uv run cleaning --steps --preview 400` — Wirksamkeit je Schritt zeigen
- `uv run cleaning --write docs/clean.txt` — bereinigten Text ablegen
- `uv run python -m rag_project.app.main_cleaning --help` — Übersicht der Optionen

Was bereinigt wird

Die Bibliothek arbeitet mit festen Mustern. Jedes Muster hat einen klaren Zweck, und die Reihenfolge ist bindend, weil spätere Schritte auf den Ergebnissen der früheren aufbauen.

Schritt	Wirkung	Muster
Steuerzeichen	entfernt Steuer- und unsichtbare Zeichen	Kontrollbereich außer Tab, Zeilenumbruch, Wagenrücklauf; Zero-Width und BOM; weiches Trennzeichen
Unicode	NFKC normalisiert zusammengesetzte und typografische Varianten	<code>unicodedata.normalize</code>
Silbentrennung	getrennte Wörter am Zeilenende werden zusammengefügt	Wort, Bindestrich, Zeilenumbruch, Wort

Schritt	Wirkung	Muster
Aufzählung	vereinheitlicht Aufzählungszeichen auf „-“	verschiedene Punktzeichen am Zeilenanfang
Leerraum	geschütztes Leerzeichen wird zum normalen, Mehrfach-Leerzeichen werden eines, drei und mehr Leerzeilen werden zwei	Läufe von Leerzeichen, Tabs und Leerzeilen

Die Reihenfolge lautet: erst Steuerzeichen entfernen, dann Unicode normalisieren, dann Silbentrennung zusammenfügen, dann Aufzählungszeichen vereinheitlichen, schließlich Leerraum normalisieren. Wer die Schritte vertauscht, bekommt andere Ergebnisse — die Silbentrennung etwa braucht die Zeilenumbrüche noch, die der Leerraumschritt später zusammenzieht.

Optionen

Option	Wirkung	Standard
paths	Quelldateien oder src:-Quellen	aus der .env
--no-unicode	Unicode-Normalisierung abschalten	aus
--no-hyphens	Silbentrennung am Zeilenende nicht auflösen	aus
--no-bullets	Aufzählungszeichen nicht vereinheitlichen	aus
--keep-empty	leere Dokumente behalten statt verwerfen	aus
--preview N	Zeichen der Vorschau, 0 schaltet sie ab	300
--show-paths	aufgelöste Pfade vor dem Laden zeigen	aus
--progress	Fortschritt je Dokument nach stderr	aus
--steps	zeigen, welcher Schritt wie viel bewirkt hat	aus
--write DATEI	bereinigten Text in dieser Datei speichern	—

Die drei Schalter --no-unicode, --no-hyphens und --no-bullets schalten einzelne Schritte ab. Sie sind für Vergleiche gedacht: Wer sehen will, was die Silbentrennung ausmacht, lässt sie einmal aus und vergleicht die Bilanz.

Bilanz und Wirksamkeit

Nach dem Lauf gibt die Anwendung `format_cleaning_stats()` aus: Zahl der Dokumente, Zeichen vorher, Zeichen nachher, die Differenz mit Prozentwert und die Zahl der Dokumente, die nach der Bereinigung leer waren. Mit `--steps` kommt zusätzlich `format_cleaning_report()` hinzu — eine Aufstellung, welcher Schritt wie viele Treffer im Rohtext hatte. So ist nachvollziehbar, welcher Schritt tatsächlich etwas bewirkt hat und welcher ins Leere greift.

Leere Dokumente

Ein Dokument, das nach der Bereinigung leer ist, wird standardmäßig verworfen und in der Bilanz als leer gezählt. Leere Chunks sind in einem Vektorindex reines Rauschen; sie belegen Platz und liefern bei jeder Suche einen Treffer ohne Inhalt. Mit `--keep-empty` bleiben sie erhalten — sinnvoll nur, wenn die Löschung selbst untersucht werden soll.

Metadaten

Die Bereinigung schreibt drei Werte in die Metadaten jedes Dokuments: `chars_before`, `chars_after` und `cleaned`. Damit bleibt nachvollziehbar, wie stark in den Text eingegriffen wurde — auch später, im fertigen Index, wenn der Rohtext längst nicht mehr vorliegt.

Netzbasierte Quellen

Wie die anderen Vorverarbeitungs-CLIs nimmt auch diese netzbasierte Quellen an: erkennbar am Präfix `src:` oder über die Optionen `--url`, `--wikipedia` und `--csv-url`. Ohne `--allow-remote` fragt die Anwendung nach. Da eine Netzquelle nicht reproduzierbar ist, sollte ihr Ergebnis einmal bereinigt und abgelegt werden.

- `uv run cleaning --wikipedia "Künstliche Intelligenz" --wiki-lang de --wiki-max-docs 2 --allow-remote`
- `uv run cleaning --url "https://example.com/scan.pdf" --allow-remote --write docs/scan_clean.txt`

Eine lokale PDF vorbereiten

Eine PDF wird zuerst bereinigt und die bereinigte Fassung als Text abgelegt; das Chunken arbeitet dann auf dieser Textdatei. Der Umweg über die Textdatei macht den Zwischenstand prüfbar, ohne den Ladevorgang zu wiederholen.

- `uv run cleaning docs/alice.pdf --write docs/alice_cleaned.txt`
- `uv run chunking docs/alice_cleaned.txt --write docs/alice_chunked.txt`

Exit-Codes

Code	Bedeutung
------	-----------

Code	Bedeutung
0	Lauf erfolgreich
1	Fehler: Pfad nicht gefunden oder Format nicht unterstützt